

Oscar Antonio Juárez Jiménez

Ingeniero de IA / Machine Learning | LLM, RAG y Sistemas Distribuidos

+52 561 973 8380 · oscar.a.juarez.j@gmail.com · linkedin.com/in/Oscar-JuJi · github.com/oscarjuji · oscarjuji.github.io

Ingeniero de IA con más de 2 años de experiencia construyendo y llevando a producción sistemas end-to-end de datos, machine learning y modelos de lenguaje de gran escala (LLM) en entornos bancarios y corporativos. Especializado en pipelines ETL con PySpark sobre AWS, microservicios contenerizados con Docker y Kubernetes, y despliegues basados en CI/CD. Historial comprobado traduciendo problemas de negocio ambiguos en resultados medibles, llevando herramientas de IA de prototipo a producción e impulsando su adopción real, con agentes LLM y asistentes conversacionales en uso diario por equipos de negocio.

EXPERIENCIA

Data Engineer | Bluetab, an IBM Company

Jul 2025 – Actualidad

Cliente: BBVA | Ciudad de México, MX

- Reduje 40 % el tiempo de preparación de datos de extremo a extremo para los equipos de analítica y machine learning, diseñando y desplegando pipelines ETL productivos en PySpark que integran más de 10 sistemas fuente en la plataforma de datos central del banco.
- Disminuí 22 % el costo de los jobs de Spark y el volumen de datos escaneados, medido como tiempo de clúster por job, reestructurando datasets y tablas en AWS S3 con particionamiento estratégico y gobierno de esquemas.
- Habilité más de 10 casos de uso de machine learning en la división de riesgo estructural, traduciendo requerimientos de features en productos de datos productivos adoptados directamente por equipos de modelado y analistas de riesgo.

AI Engineer, Innovación y Desarrollo | Grupo Salinas

Feb – Jul 2025

Prácticas profesionales | Ciudad de México, MX

- Reduje a la mitad el tiempo de gestión manual en flujos administrativos, disminuyendo 50 % el tiempo promedio de resolución por solicitud, mediante el despliegue de agentes basados en LLM y chatbots inteligentes contruidos con LangChain y las APIs de OpenAI.
- Acorté los ciclos de prototipo a validación entregando prototipos interactivos y landing pages dinámicas dentro de un proceso de Design Thinking, permitiendo a las áreas de negocio probar conceptos de IA antes de comprometer recursos de ingeniería.

PROYECTOS

Segmentación de objetos 3D en escenas de interiores con NeRF y modelos de difusión

Jun 2024 – Ago 2025

Tesis de licenciatura, IPN-ESCOM | PyTorch, NeRF, Stable Diffusion

- Mejoré 30 % la precisión de segmentación frente al baseline de U-Net, medida con Intersección sobre Unión media (mIoU) en 200 escenas de interiores anotadas, combinando clasificadores clásicos de machine learning con una arquitectura U-Net implementada en PyTorch.
- Logré edición fotorrealista de escenas 3D integrando la reconstrucción espacial de NeRF con síntesis de texturas basada en difusión con Stable Diffusion, y documenté por completo la arquitectura y el protocolo de evaluación para garantizar reproducibilidad.

Chatbot RAG para el Diario Oficial de la Federación (DOF)

Ene – Jun 2024

Proyecto personal | LangChain, LangServe, Pinecone, Docker

- Reduje el tiempo de búsqueda en documentos legales de aproximadamente 1 hora a 90 segundos por consulta—una mejora de 97 %—construyendo un sistema de Generación Aumentada por Recuperación (RAG) que responde y resume preguntas en lenguaje natural sobre el Diario Oficial de la Federación.
- Entregué el sistema como un servidor Model Context Protocol (MCP) contenerizado, usando LangChain y LangServe para la orquestación, Pinecone como backend de base de datos vectorial y Docker para builds reproducibles y despliegues sin fricción.

EDUCACIÓN

Ingeniería en Inteligencia Artificial | Instituto Politécnico Nacional (IPN) — ESCOM

Jul 2025

Promedio: 9.5/10

Materias relevantes: Aprendizaje Automático, Redes Neuronales y Aprendizaje Profundo (fundamentos y avanzado), Tecnologías del Lenguaje Natural, Procesamiento Digital de Imágenes, Cómputo Paralelo, Algoritmos Bioinspirados

HABILIDADES

Machine Learning e IA | Deep Learning, Redes Neuronales, Redes Neuronales Convolucionales (CNN), U-Net, Visión por Computadora, Procesamiento de Lenguaje Natural (NLP), Modelos de Lenguaje de Gran Escala (LLM), Generación Aumentada por Recuperación (RAG), Prompt Engineering, Evaluación de Modelos, Análisis de Errores, PyTorch, TensorFlow, scikit-learn, LangChain, LangServe, Pinecone, Stable Diffusion

Cloud, MLOps e Infraestructura | Amazon Web Services (AWS) — S3, Elastic MapReduce (EMR), AWS Glue, Identity and Access Management (IAM); Google Cloud Platform (GCP); Microsoft Azure; Docker; Kubernetes; CI/CD; Git/GitHub; MLflow; Despliegue y Monitoreo de Modelos

Ingeniería de Datos | Apache Spark, PySpark, Cómputo Distribuido, Diseño de procesos ETL, SQL, Optimización de Consultas, Modelado de Datos, Gobierno de Esquemas y Particiones, Bases de Datos Vectoriales

Lenguajes de Programación | Python, Java, SQL, R, Scala, C/C++, JavaScript/TypeScript, PHP, Go, CUDA, Bash

CERTIFICACIONES

AWS Certified Cloud Practitioner · AWS Certified AI Practitioner · Anthropic Academy — Full Course Track · Google Cloud Computing Foundations · Google Cloud Generative AI Skill Badges · Microsoft Learn AI Skills Challenge (Azure) · SAFe Scrum Master (Scaled Agile, Inc.)

IDIOMAS

Español — Nativo | Inglés — Competencia profesional (C1)